

Matrix-free Lanczos와 SLQ를 이용한 대규모 공간 스펙트럴 진단

Full eigendecomposition 없이 Vecchia precision operator에서
mode 비율과 residual energy를 추정하는 원리, 계산량, 해석 및 검증

핵심 한 문장

모든 eigenvalue와 eigenvector를 구하지 않고, $v \rightarrow \Omega v = B^T(Bv)$ 만 반복하여 진단에 필요한 aggregate spectral quantity를 직접 근사한다.

대상 규모	$n = 140,352$
Lanczos 차수	$m = 512$ (전체 차원의 약 0.365%)
Precision factor	$\Omega = B^T B$, $\text{nnz}(B) \approx 18.4$ million
핵심 산출물	mode CDF $F_\Omega(t)$, residual-energy CDF $G_r(t)$, band energy, shape discrepancy

문서 구성

- 1. 문제와 결론
 - 2. Full eigen 진단
 - 3. Matrix-free precision operator
 - 4. Covariance와 precision spectrum
 - 5. Lanczos 압축 원리
 - 6. Quadratic-form spectral approximation
 - 7. Residual Lanczos와 SLQ
 - 8. Aggregate spectral quantities
 - 9. 계산복잡도와 실제 규모
 - 10. 작은 subset에서 full eigen이 빠른 이유
 - 11. 해석 방법
 - 12. 한계와 수치적 주의점
 - 13. 구현 및 검증 체크리스트
 - 14. 최종 요약
- 부록 A. 기호와 공식
- 부록 B. 참고 문헌

먼저 구분할 용어

용어	이 문서에서의 의미
Lanczos algorithm	대칭행렬을 Krylov subspace 위의 작은 삼대각행렬로 투영하는 반복 알고리즘
Lanczos eigensolver	작은 투영행렬의 Ritz eigenpair를 통해 원행렬의 일부 eigenpair를 근사하는 방식
Lanczos quadrature	eigenpair 자체보다 $v^T f(\Omega) v$ 같은 spectral integral을 직접 근사하는 방식
SLQ	random probe와 Lanczos quadrature를 결합해 $\text{tr} f(\Omega)$ 를 추정하는 방식
Lanczos approximation	감마함수 근사를 뜻하기도 하므로 본 맥락에서는 피하는 표현

1. 문제와 결론

관측치 수가 14만을 넘는 공간모형에서는 dense covariance 또는 precision matrix의 full eigendecomposition 이 저장 단계부터 현실적이지 않다. 그러나 진단 목표가 개별 eigenvector가 아니라 넓은 eigenscale별 누적 energy라면, 전체 분해는 필요하지 않다.

FULL EIGEN



MATRIX-FREE LANCZOS



그림 1. Full eigen은 모든 mode를 계산한 뒤 집계한다. Lanczos/SLQ는 필요한 집계량을 operator action으로 직접 근사한다.

결론

현재 방법의 계산 구조는 dense $O(n^3)$ eigendecomposition이 아니라, sparse matvec을 반복하는 $O(m \cdot \text{nnz}(B))$ 구조다. SLQ probe가 s 개면 중심 비용은 $O(s \cdot m \cdot \text{nnz}(B))$ 다.

이 절약이 가능한 이유는 Lanczos 하나가 아니라 다음 세 요소의 결합이다.

- Vecchia 모형이 제공하는 sparse precision factor B
- Ω 를 만들지 않고 $\Omega v = B^T(Bv)$ 만 계산하는 matrix-free operator
- 모든 eigenpair 대신 aggregate spectral target만 근사하는 Lanczos/SLQ

2. Full eigen 진단은 무엇을 계산하는가

공분산행렬 K 가 symmetric positive definite이고 다음과 같이 분해된다고 하자.

$$K = Q\Lambda Q^T, \quad \Lambda = \text{diag}(\lambda[1], \dots, \lambda[n])$$

여기서 $q[j]$ 는 j 번째 spatial eigenmode이고 $\lambda[j]$ 는 해당 mode의 분산이다. residual r 를 $q[j]$ 방향으로 투영한 뒤 그 mode의 표준편차로 나누면 standardized coordinate가 된다.

$$z[j] = q[j]^T r / \sqrt{\lambda[j]}, \quad z[j]^2 = (q[j]^T r)^2 / \lambda[j]$$

모형이 맞고 평균구조 및 모수 추정의 영향을 잠시 무시하면 $q[j]^T r$ 은 $N(0, \lambda[j])$ 이므로 $z[j]$ 는 $N(0, 1)$, $z[j]^2$ 의 기대값은 1이다. 따라서 큰 covariance eigenvalue부터 정렬한 누적량은 다음과 같다.

$$C[k] = \sum_{j=1, \dots, k} z[j]^2 = \sum_{j=1, \dots, k} (q[j]^T r)^2 / \lambda[j], \quad E(C[k]) \approx k$$

$C(k)/k$ 가 1보다 크면 해당 누적 band에 기대보다 많은 standardized residual energy가 있고, 1보다 작으면 적다. 이 방식은 해석이 직접적이지만 모든 $\lambda(j)$ 와 $q(j)$ 를 요구한다.

Dense full decomposition의 병목

항목	복잡도	$n = 140,352$ 에서의 규모
행렬 저장	$O(n^2)$	19,698,683,904개 원소
Float64 한 행렬	$8n^2$ bytes	약 157.6 GB = 146.8 GiB
Full symmetric eigen	$O(n^3)$	$n^3 \approx 2.765 \times 10^{15}$ 규모
Eigenvector Q 저장	$O(n^2)$	K와 별도로 다시 약 157.6 GB

실제 eigensolver의 상수와 병렬화 수준에 따라 시간은 달라지지만, 이 규모에서는 메모리 요구량만으로도 dense full eigen 전략을 배제할 수 있다.

3. Matrix-free precision operator

Matrix-free는 수학적 행렬 Ω 가 존재하지 않는다는 뜻이 아니다. Ω 의 모든 원소를 배열로 만들거나 저장하지 않고, 임의의 vector v 에 대한 Ωv 를 반환하는 함수만 제공한다는 뜻이다.

$$\Omega = B^T B \quad \Rightarrow \quad \Omega v = B^T (Bv)$$

Vecchia factor B 가 sparse하면 Bv 와 $B^T u$ 모두 sparse matrix-vector multiplication으로 처리된다. 따라서 한 번의 Ωv 계산은 B 의 nonzero를 대략 두 차례 통과하는 구조다.

하지 않는 계산	실제로 수행하는 계산
dense K 생성	sparse B 저장
dense Ω 생성	Bv 와 $B^T u$
Ω^{-1} 계산	operator Ωv 호출
모든 eigenpair 계산	m 차 Krylov projection

정확성과 근사의 위치

B 가 정의하는 fitted Vecchia precision $\Omega = B^T B$ 에 대한 Ωv 는 정확하다. Lanczos가 근사하는 것은 이 operator의 전체 spectral information이다. 다만 Ω 자체가 원래 exact covariance model의 inverse를 Vecchia 방식으로 근사한 것이라면, 그 모형 근사오차는 별도로 존재한다.

4. Covariance와 precision spectrum은 어떻게 연결되는가

$\Omega = K^{-1}$ 이거나, 더 정확히는 Ω 가 fitted approximate covariance $\tilde{K}$ 의 inverse라고 하자. K 와 Ω 는 eigenvector를 공유하며 eigenvalue는 역수 관계다.

$$Kq[j] = \lambda[j]q[j] \quad \Rightarrow \quad \Omega q[j] = \mu[j]q[j], \quad \mu[j] = \lambda[j]^{-1}$$




그림 2. 큰 covariance variance mode는 작은 precision eigenvalue mode에 해당한다. 정렬 순서가 뒤집힌다.

$$(q[j]^T r)^2 / \lambda[j] = \mu[j](q[j]^T r)^2$$

따라서 K에서 큰 λ 부터 보던 기존 진단은 Ω 에서 작은 μ 부터 보면 동일하다. 이 대응은 low-precision spectrum을 large-scale covariance variation으로 해석하게 해 준다. 단, spatial scale과 eigenvalue의 관계는 covariance kernel과 sampling geometry에 따라 달라지므로 eigenvalue 크기를 물리적 파장과 일대일로 동일 시하면 안 된다.

5. Lanczos가 큰 행렬을 작은 문제로 압축하는 원리

Residual 방향의 spectral information이 목표라면 시작 vector를 $q(1) = r / ||r||$ 로 둔다. Lanczos는 Ω 를 반복 적용해서 Krylov subspace를 생성한다.

$$\text{Krylov}_m(\Omega, r) = \text{span}\{r, \Omega r, \Omega^2 r, \dots, \Omega^{(m-1)} r\}$$

이 공간의 orthonormal basis $Q_m = \{q(1), \dots, q(m)\}$ 를 구성하면, Ω 는 Q_m 위에서 작은 symmetric tridiagonal matrix T_m 으로 표현된다.

$$T_m = Q_m^T \Omega Q_m, \quad \Omega Q_m = Q_m T_m + \beta_m q_{(m+1)} e_m^T$$

한 단계의 short recurrence는 다음과 같다.

1. $w \leftarrow \Omega q(j) = B^T(Bq(j))$ 를 계산한다.
2. $\alpha(j) \leftarrow q(j)^T w$ 를 계산하고 $w \leftarrow w - \alpha(j)q(j) - \beta(j-1)q(j-1)$ 로 직교화한다.
3. $\beta(j) \leftarrow ||w||$, $q(j+1) \leftarrow w/\beta(j)$ 로 다음 basis vector를 만든다.

$$T_m = \text{tridiag}(\beta_1, \dots, \beta_{(m-1)}; \alpha_1, \dots, \alpha_m; \beta_1, \dots, \beta_{(m-1)})$$

$n = 140,352$, $m = 512$ 이면 full matrix가 아니라 512×512 의 T_m 을 분석한다. $m/n \approx 0.003648$, 즉 전체 차원의 약 0.365%다.

6. Quadratic-form spectral approximation

Lanczos의 핵심은 일부 eigenpair를 얻는 데만 있지 않다. 적절한 scalar function f 에 대해 다음 quadratic form을 직접 근사할 수 있다.

$$r^T f(\Omega) r \approx \|r\|^2 e_1^T f(T_m) e_1$$

작은 행렬을 $T_m = U \theta U^T$ 로 분해하면 근사는 quadrature node θ_l 과 weight $\|r\|^2 (U_{:,l})^2$ 의 가중합이 된다.

$$\|r\|^2 e_1^T f(T_m) e_1 = \sum_{l=1, \dots, m} w_l f(\theta_l), \quad w_l = \|r\|^2 U_{:,l}^2$$

큰 covariance eigenvalue에 해당하는 $\mu \leq t$ 영역의 누적 standardized energy를 원하면 다음 spectral filter를 선택한다.

$$f_t(\mu) = \mu \cdot 1(\mu \leq t)$$

$$r^T f_t(\Omega) r = \sum_{(\mu_j \leq t)} \mu_j (q_j^T r)^2 = \sum_{(\lambda_j \geq 1/t)} (q_j^T r)^2 / \lambda_j$$

즉 full eigen 방식은 모든 mode를 찾은 뒤 합하지만, Lanczos quadrature는 그 합에 해당하는 spectral integral을 작은 T_m 에서 바로 계산한다.

7. Residual-started Lanczos와 SLQ의 역할

누적 진단곡선에는 서로 다른 두 종류의 정보가 필요하다. 하나는 residual energy이고, 다른 하나는 threshold 안에 들어온 전체 eigenmode의 비율이다.

7.1 Residual energy measure

$$G_r(t) = n^{-1} r^T \Omega 1(\Omega \leq t) r = n^{-1} \sum_{(\mu_j \leq t)} \mu_j (q_j^T r)^2$$

r 로 시작한 Lanczos 한 번은 r 가 실제로 얼마나 각 spectral region에 투영되는지를 추적한다. 따라서 $G_r(t)$ 는 observed residual에 종속된다.

7.2 Mode-count measure

$$F_\Omega(t) = n^{-1} \text{tr } 1(\Omega \leq t) = n^{-1} \sum_{(j=1, \dots, n)} 1(\mu_j \leq t)$$

Residual vector 하나로는 전체 mode 수를 알 수 없다. $E(gg^T) = I$ 를 만족하는 Rademacher 또는 Gaussian random probe g 를 사용하면 Hutchinson identity가 성립한다.

$$E_g[g^T f(\Omega) g] = \text{tr } f(\Omega)$$

각 probe마다 Lanczos quadrature를 수행하고 평균하는 것이 stochastic Lanczos quadrature, 즉 SLQ다.

$$\text{tr } f(\Omega) \approx s^{(-1)} \sum_{i=1, \dots, s} \|g[i]\|^2 e_1^T f(T_m(i)) e_1$$

계산	시작 vector	추정 대상	무엇에 의존하는가
Residual Lanczos	$r / \ r\ $	$Gr(t)$	관측 residual
SLQ	random probes	$F\Omega(t)$	operator spectrum

모형이 맞을 때

$E(\mu[j](q[j]^T r)^2 | \Omega) = 1$ 이므로 $E(Gr(t) | \Omega) \approx F\Omega(t)$. 따라서 두 누적곡선의 차이는 특정 eigenscale에 residual energy가 과다하거나 부족한지를 보여준다.

8. Diagnostic 중 무엇이 aggregate spectral quantity 인가

Aggregate spectral quantity는 특정 j번째 mode의 값이 아니라 여러 mode 위에서 합계, 평균, 비율 또는 곡선 형태로 요약한 값이다.

진단량	종류	의미	Lanczos/SLQ 적합성
$\lambda[j], \mu[j]$	개별	j번째 eigenvalue	extreme 일부만 근사 가능
$q[j]$	개별	j번째 eigenvector	모든 vector 복원에는 부적합
$q[j]^T r$	개별	mode projection	개별 전체값에는 부적합
$z[j]^2$	개별	mode별 standardized energy	개별 전체값에는 부적합
$C(k)$ 또는 $C(k)/k$	aggregate	첫 k개 mode의 합 또는 평균	매우 적합
band energy	aggregate	특정 spectral band의 평균 energy	넓은 band에 적합
$F\Omega(t)$	aggregate	누적 mode 비율	SLQ target
$Gr(t)$	aggregate	누적 residual energy	residual Lanczos target
$r^T \Omega r$	global	전체 standardized energy	직접 matvec으로도 계산
Dshape	aggregate의 요약	두 누적곡선의 전체적 차이	곡선 근사 후 계산

예를 들어 large-covariance 쪽 첫 5%에서 $C(k)/k = 2.34$ 라면, 이는 한 eigenvector의 값이 2.34라는 뜻이 아니다. 해당 수천 개 mode에서 standardized residual energy의 평균이 2.34라는 뜻이다.

$$R_B = |B|^{(-1)} \sum_{j \in B} z[j]^2$$

원문에 제시된 예시 band 값 large 0.81, middle 1.13, small 0.87 역시 각각 특정 mode가 아니라 band 전체의 평균 energy다. 원자료와 산출물을 함께 검증하지 않은 값이므로 이 문서에서는 계산 예시로만 취급한다.

9. 계산복잡도와 실제 규모

방법	주요 시간	주요 메모리	전제
Dense full eigen	$O(n^3)$	$O(n^2)$	dense matrix 및 모든 eigenvector
Dense Lanczos	$O(mn^2)$ 중심	$O(nm)$ 또는 더 작음	Ωv 가 dense $O(n^2)$
Sparse matrix-free Lanczos	$O(m \cdot \text{nnz}(B))$ 중심	$B + \text{basis}$	$\Omega v = B^T(Bv)$
s-probe SLQ	$O(s \cdot m \cdot \text{nnz}(B))$ 중심	$B + \text{재사용 basis/workspace}$	probe run을 순차 실행 가능

Residual run 1회와 $s = 12$ 개의 SLQ probe를 사용하면 최대 13×512 회의 precision matvec이 수행된다. 각 precision matvec은 B 와 B^T 를 각각 한 번 적용한다. $\text{nnz}(B) \approx 18.4\text{M}$ 이므로 비용이 작지는 않지만 dense n^3 연산과 성격이 완전히 다르며 sparse memory bandwidth와 병렬화가 성능을 좌우한다.

메모리에서 놓치기 쉬운 항

- Q_m 전체를 Float64로 저장하면 $n \times m \times 8$ bytes다. 현재 수치에서는 약 0.575 GB, 즉 0.535 GiB다.
- Full reorthogonalization은 대략 $O(nm^2)$ 의 추가 연산과 Q_m 저장을 요구할 수 있다.
- 순수 short recurrence는 몇 개 vector만 유지할 수 있지만, Ritz vector 복원이나 재직교화가 필요하면 basis 저장량이 증가한다.
- T_m 은 작다. 512×512 dense Float64도 약 2 MiB이고, tridiagonal만 저장하면 훨씬 작다.

중요

Lanczos만 사용한다고 자동으로 scalable한 것이 아니다. Ωv 가 dense $O(n^2)$ 라면 m 번 반복도 매우 비싸다. 현재 방법이 가능한 핵심은 $\Omega = B^T B$ 에서 B 가 sparse하다는 사실이다.

10. 왜 $n = 3,200$ subset에서는 full eigen이 더 빨랐는가

측정 항목	원문 실행시간
dense K 생성	약 0.17초
full eigen	약 3.07초
Lanczos/SLQ 전체	약 49.6초

이는 모순이 아니다. $n = 3,200$ 에서는 dense matrix가 약 81.9 MB여서 메모리에 들어가고, LAPACK의 symmetric eigensolver가 고도로 최적화되어 있다. 반면 benchmark의 Lanczos/SLQ는 residual run, 32개 random probe, probe별 최대 512 iterations, 반복 matvec과 orthogonalization을 수행했다.

따라서 subset 실험의 목적은 속도 우위를 보이는 것이 아니라 다음을 검증하는 것이다.

- 동일한 subset에서 full eigen curve와 Lanczos/SLQ curve가 충분히 가까운가?
- m 과 probe 수를 늘릴 때 broad-band 진단이 안정화되는가?
- 근사오차가 실제 진단 결론을 바꾸지 않는가?

작은 n 에서는 full eigen이 더 빠를 수 있다. 큰 n 에서 Lanczos의 장점은 더 빠른 상수항이 아니라, dense 저장과 n^3 scaling을 피한다는 점이다.

11. 누적곡선과 band energy를 해석하는 방법




그림 3. 개념도. 실제 데이터 결과가 아니라 $F(t)$ 와 $G(t)$ 의 관계를 설명하기 위한 예시.

가로축을 $F(t)$, 세로축을 $G(t)$ 로 두면 이상적인 기준은 대각선이다. 특정 구간에서 G 가 F 보다 빠르게 증가하면 그 spectral band의 residual energy가 기대보다 크다는 뜻이다.

관측 패턴	통계적 의미	가능한 모형 해석
large-covariance band에서 $G > F$	smooth/large-scale mode의 residual energy 과다	mean structure, long-range dependence, large-scale random effect 부족
middle band에서 $G > F$	중간 scale mismatch	range 또는 covariance shape 부적합 가능
small-covariance band에서 $G > F$	rough/local mode의 residual energy 과다	nugget, measurement error, local dependence 부족 가능
$G < F$	해당 band의 energy 부족	over-smoothing, variance 과대, fitted-parameter 효과 가능
전체 $G(\infty) \neq 1$	global standardized energy mismatch	전체 variance calibration 또는 df 조정 점검

위 해석은 진단적 가설이지 단독으로 원인을 식별하는 증거는 아니다. mean misspecification, parameter estimation, non-Gaussian tails, outlier, ordering-dependent Vecchia approximation도 유사한 패턴을 만들 수 있다.

12. Lanczos/SLQ가 해주는 것, 해주지 않는 것, 주의점

잘하는 것	일반적으로 보장하지 않는 것
전체 eigenvalue CDF의 근사	모든 n 개 eigenvalue의 정확한 목록
넓은 low/middle/high band의 mode 비율	매우 좁은 hard band의 정확한 membership

잘하는 것	일반적으로 보장하지 않는 것
누적 및 band residual energy	모든 $z(j)^2$ 의 정확한 개별 순위
몇 개의 extreme Ritz values	모든 eigenvector의 정확한 공간 패턴
matrix function quadratic forms	$m \ll n$ 일 때 full spectral reconstruction

12.1 Indicator function은 매끄럽지 않다

$f_t(\mu) = \mu \mathbf{1}(\mu \leq t)$ 또는 $\mathbf{1}(\mu \leq t)$ 는 threshold에서 불연속이다. Lanczos quadrature는 log, inverse 같은 smooth function보다 hard step에서 느리게 수렴할 수 있다. 그러므로 매우 좁은 band나 개별 eigenvalue 근처의 jump는 불안정할 수 있다.

- 넓은 quantile band를 사용하고 threshold grid를 지나치게 촘촘하게 해석하지 않는다.
- m 을 증가시킨 convergence study를 수행한다.
- 필요하면 step function을 smooth transition으로 바꾸거나 spectral density smoothing을 사용한다.

12.2 Finite precision과 orthogonality loss

Exact arithmetic의 Lanczos vector는 orthogonal하지만 floating-point에서는 이미 수렴한 Ritz direction이 다시 나타나는 ghost eigenvalue 문제가 생길 수 있다. full 또는 selective/partial reorthogonalization, residual norm monitoring이 필요하다.

12.3 Random-probe uncertainty

SLQ는 stochastic estimator이므로 probe seed와 수 s 에 따라 흔들린다. probe 간 분산 또는 여러 seed 반복으로 Monte Carlo standard error를 보고하고, 진단곡선에는 uncertainty band를 함께 표시하는 것이 좋다.

12.4 Fitted residual은 독립 $N(0, K)$ 가 아니다

고정효과와 covariance parameter를 같은 데이터에서 추정하면 residual의 유효 자유도가 감소하고 eigenmode 간 분포가 단순 chi-square(1)과 달라질 수 있다. 특히 mean design X 와 강하게 겹치는 low-frequency mode는 영향을 많이 받는다.

- 가능하면 generalized residual 또는 mean-space projection을 명시한다.
- 기대선 $Gr = F$ 만 쓰기보다 fitted model에서 parametric bootstrap envelope를 만든다.
- Vecchia ordering과 neighbor size를 바꿔 구조적 민감도를 확인한다.

13. 권장 구현 및 검증 체크리스트

A. Operator 검증

- 작은 subset에서 explicit Ω 와 matrix-free $B^T(Bv)$ 의 결과가 numerical tolerance 안에서 일치하는지 확인한다.
- 대칭성 검사: $u^T \Omega v$ 와 $v^T \Omega u$ 가 일치하는지 random vectors로 확인한다.
- positive definiteness 또는 near-null direction을 점검하고 breakdown 처리 규칙을 기록한다.

B. Lanczos convergence

- $m = 128, 256, 512$ 등으로 늘리며 $F\Omega$, Gr, band averages가 안정화되는지 비교한다.
- Ritz residual과 orthogonality loss를 모니터링한다.
- hard threshold 주변의 결과를 단일 점이 아니라 band 평균으로 해석한다.

C. SLQ uncertainty

- probe 수 s 를 증가시키며 curve와 주요 scalar summary의 Monte Carlo error를 기록한다.
- Rademacher probe, random seed, normalization convention을 명시한다.
- probe별 결과를 저장해 pointwise standard error 또는 bootstrap band를 계산한다.

D. Full-eigen benchmark

- $n \approx 3,200$ 처럼 exact eigen이 가능한 subset에서 동일한 sorting과 normalization을 사용한다.
- curve sup error, integrated absolute error, band-energy error를 수치로 비교한다.
- 속도보다 진단 결론의 재현성과 approximation bias를 평가한다.

E. Statistical calibration

- fitted model에서 residual을 반복 모의하여 null envelope를 구축한다.
- mean estimation, covariance estimation, Vecchia approximation을 모두 simulation pipeline에 포함한다.
- band 경계와 tuning parameters를 결과를 본 뒤 선택했다면 multiplicity 또는 탐색 편향을 설명한다.

14. 최종 요약

Full eigen

$K = Q \Lambda Q^T$ 를 통해 모든 eigenvalue와 eigenvector를 구한다.

시간 $O(n^3)$, 메모리 $O(n^2)$. $n = 140,352$ 에서는 dense storage부터 비현실적이다.

Matrix-free Lanczos / SLQ

$v \rightarrow \Omega v = B^T(Bv)$ 를 반복하고, $m \times m$ 인 T_m 만 분석한다.

Residual-started Lanczos는 Gr(t), random-probe SLQ는 $F\Omega(t)$ 를 근사한다.

이 진단은 14만 개 mode 각각을 복원하는 대신, eigenscale별 mode 비율과 standardized residual energy의 총량을 비교한다. 따라서 target 자체가 aggregate quantity이며 Lanczos quadrature와 구조적으로 잘 맞는다.

sparse Vecchia precision + matrix-free matvec + Lanczos/SLQ

이 조합은 dense $O(n^3)$ 문제를 반복적인 sparse operator 계산으로 바꾼다. 정확성은 m , probe 수, orthogonalization, threshold smoothing 및 fitted-model calibration으로 검증해야 한다.

부록 A. 기호와 핵심 공식

기호	정의
n	관측치 또는 spatial degree of freedom 수
K 또는 $K\text{-tilde}$	covariance matrix 또는 fitted approximate covariance
Ω	precision operator; $\Omega = K\text{-tilde}^{-1} = B^T B$
B	sparse Vecchia precision factor
$\lambda_{[j]}$	K 의 j 번째 covariance eigenvalue
$\mu_{[j]}$	Ω 의 j 번째 precision eigenvalue; $\mu_{[j]} = 1/\lambda_{[j]}$
r	분석 대상 residual vector
m	Lanczos iterations / Krylov dimension
s	SLQ random probe 수
Q_m	Krylov subspace의 orthonormal basis
T_m	$Q_m^T \Omega Q_m$ 인 $m \times m$ tridiagonal projection
$F_\Omega(t)$	$\mu \leq t$ 인 eigenmode의 누적 비율
$Gr(t)$	$\mu \leq t$ 인 mode의 누적 standardized residual energy

$$z[j]^2 = \mu[j](q[j]^T r)^2 = (q[j]^T r)^2 / \lambda[j]$$

$$E[G_r(t) \mid \Omega] \approx F_\Omega(t)$$

$$G_r(\infty) = n^{-1} r^T \Omega r$$

$$\text{Cost}(\text{residual}) \approx O(m \cdot \text{nnz}(B))$$

$$\text{Cost}(\text{SLQ}) \approx O(s \cdot m \cdot \text{nnz}(B))$$

부록 B. 관련 참고 문헌

1. Lanczos, C. (1950). An iteration method for the solution of the eigenvalue problem of linear differential and integral operators. *Journal of Research of the National Bureau of Standards*, 45, 255-282.
2. Golub, G. H., & Van Loan, C. F. *Matrix Computations*. Krylov subspace와 symmetric Lanczos의 표준 참고서.
3. Ubaru, S., Chen, J., & Saad, Y. (2017). Fast estimation of $\text{tr}(f(A))$ via stochastic Lanczos quadrature. *SIAM Journal on Matrix Analysis and Applications*, 38(4), 1075-1099. DOI: 10.1137/16M1104974.
4. Dong, K., Eriksson, D., Nickisch, H., Bindel, D., & Wilson, A. G. (2017). Scalable log determinants for Gaussian process kernel learning. *NeurIPS 30*. Spatial precipitation, log-Gaussian Cox process, Chicago crime 사례 포함.
5. Pleiss, G., Gardner, J., Weinberger, K., & Wilson, A. G. (2018). Constant-time predictive distributions for Gaussian processes. *ICML*. Lanczos-based LOVE predictive covariance approximation.
6. Genton, M. G. (2007). Separable approximations of space-time covariance matrices. *Environmetrics*, 18, 681-695. SVD Lanczos를 이용한 Kronecker covariance approximation.
7. Gyger, T., Furrer, R., & Sigrist, F. (2026). Iterative methods for full-scale Gaussian process approximations for large spatial data. *SIAM/ASA Journal on Uncertainty Quantification*. DOI: 10.1137/25M1731320.

문서 범위

이 문서는 사용자가 제공한 기술 메모를 기반으로 원리와 계산구조를 재정리한 설명자료다. 원문의 실행시간과 band 값은 해당 실행 로그 및 원자료를 독립적으로 재분석한 결과가 아니므로, empirical result로 인용할 때는 원 코드와 산출물의 재현성 검증이 필요하다.